Proyecto 2020
ASIGNATURA LIC MI CARRERA
Orientaciones metodológicas:
Este es el tema de mi clase

Estudiante Pérez Pérez *

Ejercicios

Ejercicio 1 *Genere una Población normal de tamaño 500, seleccione 8 muestras de tamaños varios(Muy mayor que 30, mayor que 30, 30, 20), 4 muestras con remplazo y 4 sin remplazo.*

a. Calcule para cada una de las muestras los Estadísticos Descriptivos, de la Conferencia 1.

b. Calcúlelos en la población inicial. Analice las diferencias.

c. Grafique los resultados.

d. Para cada muestra calcule los intervalos de confianza para la media y la varianza.

e. Analice las diferencias en los resultados de las muestras de tamaños similares.

Propuesta de distintos ejercicios de la clase, para desarrollar las habilidades a crear durante la clase.

Ejercicio 2 *Aqui va orden del ejercicio 2.*

Ejercicio 3 *Analizando los datos del archivo "adult.data.csv"(Equipo 10), ¿Hay diferencias significativas entre el promedio de años dedicados a la educación y la cantidad de ingreso de los censados?*

Objetivos

a. Esta sección va dedicada a los objetivos de la clase, las metas para el encuentro y ciertas especificidades que considere de importancia resaltar durante el trancurso de la clase.

b. Según la temática se pueden hacer alusión a los medios de enseñanza utilizados convenientemente.

Introducción

(Xmin')

(Como introducir mi clase?)

- Recursos para motivar la clase.
- Recuento por los antecedentes de los resultados o investigadores.
- Esta no tiene que venir acompañada por plecas, solo es un ejemplo.

Teorizando un poco

(Ymin')

a. **(Un Teorema interesante)** Tras la introducción se podrán construir las secciones que se estimen convenientes para el desarrollo de la clase.

b. **(Un brillante algoritmo)** Los nombre de cada una de estas secciones quedan a la elección del autor.

*Soy estudiante de X año de mi carrera.

Ejercicio 1

(código referente al ejercicio en exercise_1.R)

Diferencias entre las muestras y la población

Se genera una población inicial con 500 elementos y una distribución normal con media 0 y varianza 1. Luego se extraen 4 muestras sin remplazo, cada una de tamaño 200, 60, 30 y 20 respectivamente. Luego se extraen otras 4 de igual tamaño a las anteriores y con remplazo. Para cada muestra se calculan media, mediana, varaiación y desviación estándar. Los datos son continuos y la probabilidad de que 2 datos sean iguales es teoricamente 0, por ende asumimos que la moda nunca existe.

La exactitud de los estimadores puntuales fluctua en cada prueba realizada, la fluctuación es mayor o menor dependiendo del tamaño de las muestras.
Las muestras de mayor tamaño presentan estimadores más exactos, en cambio, las de menor tamaño suelen estar más alejadas del valor real. Esto se debe a que en las muestras más grandes cuando tienen un caso extremo no representativo de la población su impacto queda disminuido por el resto de los datos no extremos, mientras que en las muestras pequeñas la existencia de uno de estos altera considerablemente la información extraída.

Queda reflejada entonces una dependencia directa que existe entre los resultados de una muestra y la calidad de sus datos. Podemos deducir entonces la importancia de que las muestras esten compuestas por datos fiables, incluso más cuando la muestra es pequeña.

Para visualizar los resultados utilizamos un gráfico de cajas y bisagras y gráficos de barras. El primero por su propiedad para dar en una sola imagen percentiles, mediana, mínimo y máximo, además si las partes de las cajas se encunetran simetricas y centrada en los datos indica que estos siguen una dsitribución normal. El gráfico de barras lo utilizamos para visualizar las diferencias de la media y la varianza en las distintas muestras y población.

Como ejemplo, en la figura[1] se puede apreciar un gráfico de cajas y bigotes distribuidos consecutivamente, donde cada gráfico corresponde a una muestra distinta. La caja de las muestras de tamaño 200 se encuentran generalmente alineadas y bien formadas, indicador de que sus datos mantienen la distribución normal de la población de la cual fueron extraídos. La representación de las otras muestras puede estar bien formadas o no. En este ejemplo es posible ver que las muestras pequeñas la caja esta deformada por lo que sus datos no son representativos de la población, al igual que la muestra de tamaño 60 sin remplazo, mientras que la muestra de tamaño 60 con remplazo sus datos están relativamente alineados con los de la población.

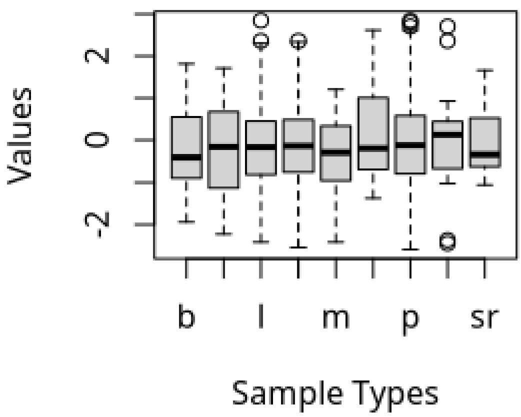

p: población, l: muestra de tamaño 200, b: tamaño 60, m: tamaño 30 y s: tamaño 20. Si tiene r al final es muestra con remplazo

Intervalos de Confianza y diferencias entre las muestras de igual tamaño

Se estiman los intervalos de confianza para la media y la varianza con un nivel de signifación del 5 por ciento. Luego se comparan los resultados entre las muestras de mismo tamaño.

Durante todas las pruebas realizadas todos los intervalos de confianza fueron correctos, es decir, la media y la varianza de la población siempre estuvieron dentro de los intervalos calculados. La diferencia más notable que ocurrió de manera consistente en todas las pruebas realizadas fue la diferencia de tamaño en los

[1] Posible visualizar en mayor detalle cuando se ejecute el código.

intervalos entre las muestras con mayor cantidad de datos y menor cantidad respectivamente. Una muestra con menor cantidad de datos resulta en un intervalo de confianza más amplio.

Durante nuestras pruebas no hubo una diferencia notable en los intervalos de confianza entre las muestras extraidas con remplazo y sin remplazo.

Conocimientos adquiridos

Podemos decir a modo de análisis final que el proceso de obtener una muestra no basta solo con recoger datos aleatorios, es importante que los datos sean representativos de la población. En caso de que no se tenga información sobre la poblacion obtener la mayor cantidad de datos posibles.

Tambien visaulizamos como las fórmulas estudiadas se adapantan y complementan para dar un resultado correcto. En el caso de las muestras de mayor cantidad de datos sus estimadores puntuales usualmente son más exactos que en las muestras pequeñas y estas últimas en consecuencia tienen un intervalo de confianza de mayor tamaño como compensación a la inexactitud de sus estimadores puntuales.

Ejercicio 2

Ejercicio 3

El problema trata sobre comparar la medias de años de educacion de los grupos de ingresos $\leq 50K$ y $> 50K$, y ver si hay alguna diferencia significativa entre esas medias.

El código referente a este ejercicio esta en el archivo exercise_3.R

Para lograr lo anterior se dividió todos los datos del archivo csv en dos grupos: un grupo tiene ingresos $\leq 50K$ y otro grupo tiene ingresos de $> 50K$.

Luego de realizar la división se escogieron dos muestras sin reemplazo de tamaño $N = 60$ cada una.

Por lo que el problema se reduce a una prueba de hipótesis para la comparación de las medias de dos poblaciones Normales.

Las hipótesis para la prueba que se escogieron fueron:

$$H_0 : \mu_1 = \mu_2$$

$$H_1 : \mu_1 \neq \mu_2$$

Donde μ_1 es la media de años de educación de la población de personas que poseen ingresos por debajo de los $50K$(inclusivo) y μ_2 es la media de años de educación de la población de personas que poseen ingresos por encima de los $50K$.

Se asumió que no se conocían las varianzas de dichos grupos(o que era muy costoso calcularlas). Por lo que para hacer la prueba de hipótesis de la media se hace primero una prueba de hipótesis para la igualdad de las varianzas.

Parte del codigo para la hipotesis de varianza

```
result <- var.test(sample1,
sample2, alternative = "two.sided")
```

Luego de establecer la igualdad o desigualdad de varianza se procede a realizar la prueba de la media:

Parte del codigo para la hipotesis de la media

```
result <-t.test(sample1,sample2,
alternative = alt, var.equal = varequal)
```

Finalmente se compara el resultado del *p-value* de *result* con un valor α preestablecido y si es menor se rechaza la hipótesis nula.

Analíticamente

Se hace primero la prueba de varianza.

Los datos se tomaron del script referente al ejercicio.

$H_0 : \sigma_1^2 = \sigma_2^2$

$H_1 : \sigma_1^2 \neq \sigma_2^2$

$$F = \frac{S_1^2}{S_2^2} = \frac{6.37}{5.13} = 1,24$$

$$F_{1-\alpha/2}(n_1 - 1, n_2 - 1) = F_{0.975}(59, 59) = 1.67$$

$$F_{\alpha/2}(n_1 - 1, n_2 - 1) = F_{0.025}(59, 59) = 0.597$$

Como $F > F_{\alpha/2}(n_1 - 1, n_2 - 1)$ y $F < F_{1-\alpha/2}(n_1 - 1, n_2 - 1)$ no se puede descartar H_0 por lo que se asume que $\sigma_1^2 = \sigma_2^2$

$$T_{\bar{X}-\bar{Y}} = \frac{\bar{X} - \bar{Y}}{\sqrt{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}} \sqrt{\frac{n_1 n_2 (n_1 + n_2 - 2)}{n_1 + n_2}} = 3.7$$

$$t_{1-\alpha/2}(n_1 + n_2 - 2) = t_{0.975}(116) = 1.98$$

Como $|T_{\bar{X}-\bar{Y}}| > t_{1-\alpha/2}(n_1+n_2-2)$ se cumple la región crítica y se descarta H_0 pudiendo afirmarse que se aprecian diferencias significativas.

Conclusiones

(Cierta cantidad de minutos')

Se resumirán los resultados más destacados ejercitados en la actividad.

Se puede hacer mención de aplicaciones del método estudiado, posibles investigaciones o repercusiones en la cotidianidad. Así como los elementos de mayor significación.

Estudio Independiente

(Algun tiempo')

Orientar y comentar los ejercicios siguientes:

Ejercicio 4 *De creerlo conveniente, la asignación de tareas para el estudio independiente, o la asignación de evaluaciones.*

Ejercicio 5 *La cantidad de los mismos es a conveniencia aunque podría ser de ayuda su justificación.*

Ejercicio 3

Para concluir, la solución de los ejercicios propuestos.

Ejercicio 4

El esquema de clase es variable y queda sujeto a la voluntad del participante, lo que si deberá ajustarse a los requisitos de la convocatoria oficial.